# به نام خدا



آشنایی با ابزار کافکا تهیهکنندگان: پارسا عنایتی، مهدی اکبری

برنامه نویسی وب

یک فروشگاه آنلاین را در نظر بگیرید که نیاز دارد تراکنشهای مشتریان را در زمان واقعی پردازش کند. مشکلاتی که باید حل شود شامل:

- 1. ثبت بلادرنگ تراکنشها :نیاز به ثبت تمام تراکنشها به محض وقوع.
- 2. **پردازش همزمان** :تحلیل بلادرنگ داده ها برای پیشنهادات شخصی سازی شده و موجودی انبار.
  - 3. مقیاس پذیری :مدیریت حجم بالای تراکنش ها در زمان تخفیفات یا فروش ویژه.

در صورت استفاده از رامحل های قدیمی و سیستمهای سنتی پیامرسانی یا پایگاههای داده به یکسری محودیتها برمیخوریم:

•محدودیت مقیاس پذیری :بسیاری از سیستمهای پیامرسانی سنتی مانند ActiveMQ یا RabbitMQ با محدودیتهای مقیاس پذیری مواجه هستند و در صورت افزایش حجم دادهها، عملکرد آنها کاهش می یابد.

•پایداری و قابلیت اطمینان :این سیستمها ممکن است در صورت خرابی سرور، دادهها را از دست بدهند یا با مشکلات بازیابی مواجه شوند.

•تاخیر بالا : ثبت بلادرنگ تر اکنشها در پایگاه دادههای سنتی ممکن است باعث افزایش تاخیر شود و نتواند نیاز به یردازش بلادرنگ را برآورده کند.

•محدودیتهای همزمانی :پایگاههای داده در مواجهه با حجم بالای تراکنشها ممکن است با مشکلات همزمانی مواجه شوند که منجر به کاهش کارایی سیستم میشود.

•محدودیت در حجم داده ها: ابزار های پردازش بلادرنگ مانند Storm یا Flink ممکن است در مواجهه با حجم بسیار بالای داده ها با مشکلات کارایی و مقیاس پذیری مواجه شوند.

•پیچیدگی در مدیریت :مدیریت و نگهداری این ابزارها ممکن است پیچیده و هزینهبر باشد.

•محدودیت در توزیع بارکاری :بسیاری از سیستمهای توزیعشده سنتی نمیتوانند به صورت کار آمد بارکاری را بین سرورها توزیع کنند و با افزایش حجم دادهها، کارایی آنها کاهش میابد.

•مشكلات هماهنگى :هماهنگى بين سرورها در سيستمهاى توزيعشده ممكن است پيچيده و پرهزينه باشد.

#### راه حل چیست؟

استفاده از ابزاری که قابلیتهای زیر را داشته باشد:

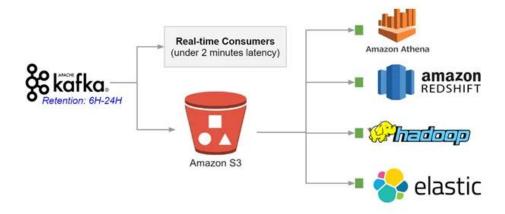
- •مقیاس پذیری بالا :تو انایی مدیریت حجم عظیم داده ها و افز ایش بار کاری.
  - پایداری و قابلیت اطمینان : حفظ داده ها با استفاده از replication.
    - •عملكرد بالا : پردازش ميليون ها پيام در ثانيه با تاخير كم.
- انعطاف پذیری :معماری publish-subscribe برای انتشار و اشتراک داده ها بین سیستمها.
  - •پردازش بلادرنگ : تحلیل و پردازش داده ها به صورت لحظهای.
    - •جامعه کاربری فعال : منابع آموزشی و پشتیبانی گسترده.
- •سازگاری با تكنولوژی های موجود :ادغام آسان باFlink ،Spark ، Hadoopو ساير ابزار ها.

اینجاست که مفهومی با نام Apache Kafka به کمک مهندسان نرمافز ار میآید.

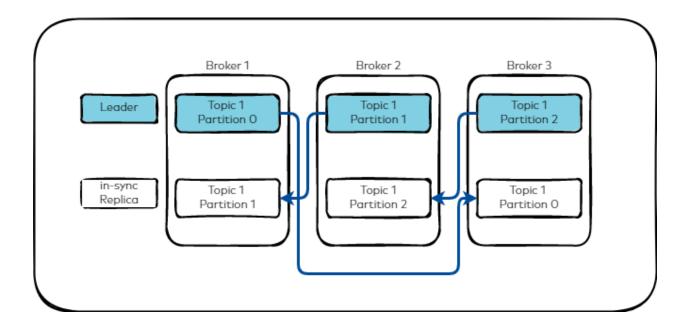


Apache Kafka یک مخزن داده توزیع شده و به عبارتی یک Message Broker است که برای دریافت و پردازش داده های استریمینگ داده هایی هستند که به طور پیوسته توسط هزاران منبع داده تولید می شوند و معمولاً به صورت همزمان ارسال می گردند. یک پلتفرم استریمینگ باید بتواند این جریان پیوسته از داده ها را مدیریت کرده و داده ها را به صورت ترتیبی و تدریجی پردازش کند.

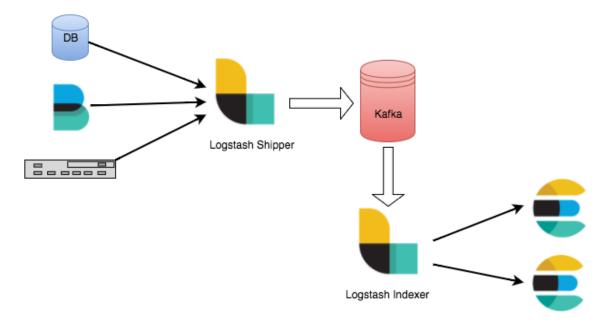
Kafka به گونهای طراحی شده است که بتواند حجم بسیار زیادی از دادهها را به صورت کارآمد و با تاخیر کم پردازش کند. ساختار توزیعشده آن به کاربران امکان میدهد تا سیستم را بر اساس نیاز های خود به سادگی گسترش دهند و منابع را به طور پویا مدیریت کنند.



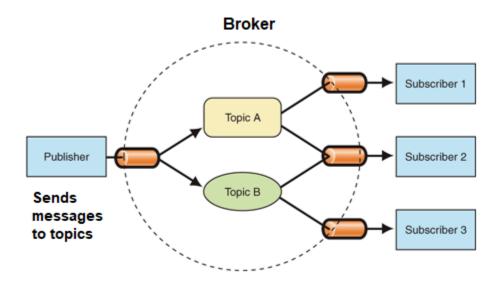
یکی از ویژگیهای کلیدی Kafka ، استفاده از مفهوم replication است که دادهها را بین چندین سرور کپی میکند. این ویژگی باعث میشود که حتی در صورت بروز خرابی در یک یا چند سرور، دادهها از دست نروند و سیستم همچنان به کار خود ادامه دهد.



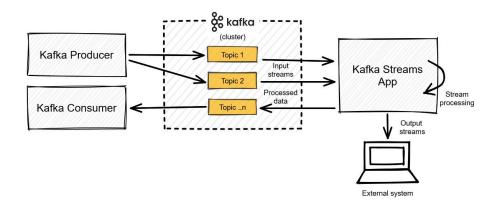
Kafka برای دستیابی به عملکرد بالا بهینهسازی شده است. این ابزار میتواند میلیونها پیام در ثانیه را با تاخیر کم پردازش کند. به همین دلیل، برای کاربردهایی که نیاز به پردازش سریع دادهها دارند، مانند تحلیل دادههای بلادرنگ و مانیتورینگ، بسیار مناسب است.



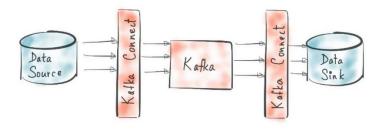
Kafka از معماری publish-subscribe بهره میبرد که به کاربران امکان میدهد تا داده ها را به صورت انعطاف پذیر بین سیستمها و سرویسهای مختلف منتشر و مشترک شوند. این معماری امکان ساخت سیستمهای پیچیده و تطبیق پذیر را فراهم میکند

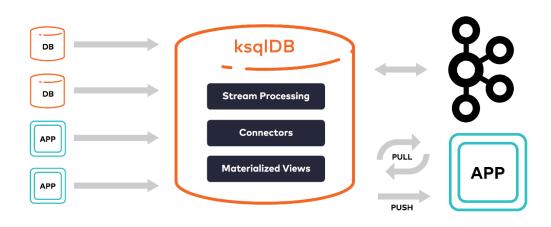


Kafka با داشتن اکوسیستم گستردهای از ابزارها و افزونهها، امکانات متنوعی برای پردازش و تحلیل دادهها ارائه میدهد. برخی از این ابزارها شامل Kafka Streams برای پردازش استریمها، Kafka Connect برای اتصال به سیستمهای مختلف و KSQL برای تحلیل دادهها با استفاده از SQL می شوند.



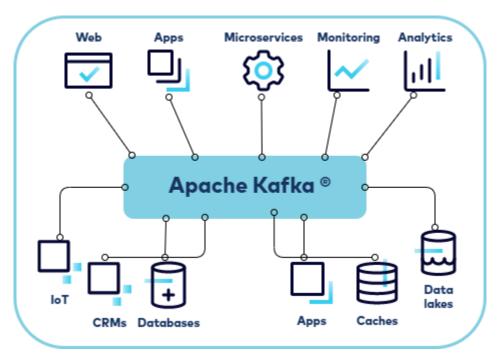
# & KAFKA CONNECT





Kafka به کاربران امکان میدهد تا داده ها را به صورت بلادرنگ پردازش و تحلیل کنند. این ویژگی برای کاربردهایی مانند تحلیل رفتار کاربران، پردازش تراکنشهای مالی، مانیتورینگ سیستمها و دستگاهها بسیار مفید است.

Apache Kafka دارای یک جامعه کاربری بزرگ و فعال است که به توسعه، بهبود و پشتیبانی از این ابزار کمک میکند. وجود منابع آموزشی متعدد، مستندات جامع و انجمنهای پشتیبانی به کاربران جدید کمک میکند تا به سرعت با Kafka آشنا شوند و از آن استفاده کنند.



Kafka با بسیاری از فناوری ها و ابزارهای موجود در حوزههای مختلف از جمله Flink ، Spark ، Hadoop و Elasticsearch سازگاری دارد. این سازگاری امکان ادغام و استفاده از Kafka در معماری های موجود را تسهیل میکند.



# ساختار و مفاهیم کلیدی در Kafka

# Topic .1

یک Topic در Kafka نمایانگر یک جریان داده است. داده ها در Kafka به صورت دسته های جداگانه ای که Topic نامیده می شوند، ساز ماند هی می شوند.

• کاربرد: تولیدکنندهها (Producers) دادهها را به Topicهای خاصی می فرستند و مصرف کنندهها (Consumers) دادهها را از این Topicها دریافت می کنند.

## 2. پارتیشن (Partition)

هر Topicای میتواند به چندین پارتیشن تقسیم شود. هر پارتیشن یک بخش از دادههای یک Topic را نگهداری میکند.

#### • مزایا:

- م مقیاسپذیری : تقسیم داده ها به پارتیشن ها امکان پر دازش موازی و افزایش مقیاسپذیری را فراهم میکند.
- پایداری : هر پارتیشن میتواند بر روی چندین سرور (بروکر) نگهداری شود تا در صورت خرابی یکی
   از سرور ها، داده ها از دست نروند.

### 4. مصرفکننده (Consumer)

مصرفکننده ها داده ها را از Topic های خاص در Kafka دریافت و پردازش میکنند.

#### 5. بروکر(Broker)

سرورهایی که پیامها را دریافت و ذخیره میکنند. هر Kafka cluster شامل یک یا چند بروکر است.

• کاربرد: بروکر ها پیامها را در پارتیشنهای Topicها ذخیره میکنند و در اختیار مصرفکننده ها قرار میدهند.

#### Replication .6

هر پارتیشن میتواند چندین نسخه (replica) داشته باشد که بر روی بروکر های مختلف نگهداری میشوند.

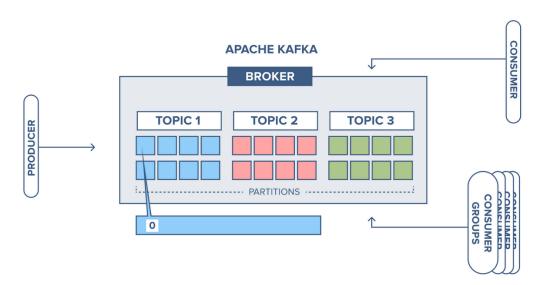
• مزایا : این ویژگی باعث افزایش پایداری و قابلیت اطمینان Kafka می شود، زیرا در صورت خرابی یکی از بروکرها، دادهها از نسخههای دیگر بازیابی می شوند.

# 7. گروه مصرفکننده (Consumer Group)

مجموعه ای از مصرف کننده ها که با هم کار می کنند تا پیام ها را از یک Topic دریافت و پردازش کنند.

گروههای مصرفکننده باعث افزایش مقیاسپذیری و توزیع بارکاری میشوند. هر پیام در یک Topic تنها توسط یک مصرفکننده از هر گروه پردازش میشود.

همچنین یکی از اعضای گروه (معمولا عضوی که زودتر عملیات مصرف را شروع کرده است) به عنوان leader انتخاب می شود تا در صورت بروز اتفاقاتی همچون dead شدن یکی از اعضا، عملیات assign یک پارتیشن را که حالا عضو آن مرده است، به عضوی دیگر انجام دهد.



# ساختار داخلی پیامها در Kafka

#### اجزای اصلی پیام در Kafka

#### Record: .1

- هر پیام در Kafka به عنوان یک رکورد (Record) شناخته می شود.
- o هر رکورد شامل یک کلید(key) ، یک مقدار (value) و متادیتاهای دیگری است.

#### **Key**: .2

- کلید می تواند به توزیع پیامها در پارتیشنها کمک کند. پیامهایی با کلید یکسان به یک پارتیشن خاص ارسال می شوند.
  - کلید میتواند اختیاری باشد. اگر کلید استفاده نشود، توزیع پیامها به صورت تصادفی انجام میشود.

#### **Value**: .3

- مقدار اصلی بیام است که حاوی دادههای مورد نظر برای انتقال است.
- o مقدار مى تواند هر نوع داده اى باشد كه به صورت بايت ها قابل ذخيره و انتقال باشد. (... UTF-8, Base-64)

#### Offset: .4

- ) هر پیام در یک پارتیشن دارای یک شناسه منحصر به فرد به نام offset است.
- Offset نشاندهنده موقعیت پیام در پارتیشن است و توسط Kafka برای مدیریت پیامها و پیگیری وضعیت مصرف کننده ها استفاده میشود.

#### Timestamp: .5

- o هر رکورد می تواند یک تایم استمپ داشته باشد که زمان تولید یا زمان دریافت پیام توسط Kafka را نشان می دهد.
  - تایماستمپ به تحلیل زمانی و مدیریت پیامها کمک میکند.

#### **Headers**: .6

- o.11.0.0 از نسخه 0.11.0.0 به بعد، از هدرها (Headers) پشتیبانی میکند.
- o هدر ها شامل جفتهای کلید-مقدار اختیاری هستند که متادیتای اضافی در مورد بیام ارائه میدهند.

یک بیام کامل در Kafka میتواند به صورت زیر باشد:

```
Record {
    Key: "user123",
    Value: "OrderID: 456, Amount: 789",
    Offset: 42,
    Timestamp: 1627584000,
    Headers: {
        "Source": "web",
        "Content-Type": "application/json"
    }
}
```

# نحوه ذخيرهسازي پيامها در Kafka

پیامها در Kafka در داخل لاگها ذخیره میشوند که در پارتیشنها نقسیم شدهاند. هر پارتیشن یک لاگ ترتیبدار از پیامهاست که به ترتیب ورود ذخیره میشوند. این لاگها به صورت توالیدار نوشته و خوانده میشوند.

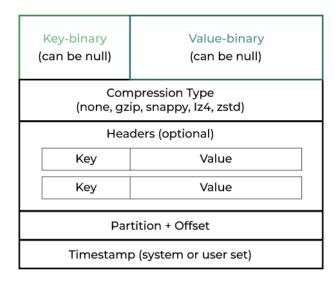
#### Log Segments:

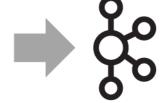
- هر پارتیشن به چندین بخش (Segment) تقسیم می شود که هر کدام یک فایل فیزیکی در دیسک هستند.
- وقتی اندازه یک بخش از حد معین عبور کند یا زمان معینی بگذرد، Kafka یک بخش جدید ایجاد میکند.

#### *Indexes:*

- برای دسترسی سریع به پیامها، Kafka از ایندکسها استفاده میکند.
- هر پارتیشن دارای آیندکس های جداگانه ای برای Offset و Time است که دسترسی به پیام ها را سریعتر میکند.

Kafka Message created by the producer





#### مفاهیم پیشرفته در Kafka

#### **Consumer Offset**

- Offset :یک شناسه منحصر به فرد است که نشاندهنده موقعیت هر پیام در داخل یک پارتیشن است. مصرفکنندهها (Consumers)از offset برای پیگیری پیامهایی که پردازش کردهاند استفاده میکنند.
  - **ذخیرهسازی**: Offsetها میتوانند به صورت دستی یا خودکار commit شوند و در یک Topic خاص به نام commit خاص به نام دخیره میشوند.
- مدیریت:مصرفکننده ها میتوانند با استفاده از API های offset ، Kafka های خود را مدیریت کنند و تصمیم بگیرند که از
   کجا خواندن پیامها را شروع کنند.

#### Kafka 🛂 Acknowledgment

- Acknowledgment (ACK) در Kafka فرایندی است که در آن تولیدکننده (Producer) تأیید میکند که پیام به درستی توسط بروکر (Broker) دریافت شده است.
  - انواع:ACK
  - o acks=0 : تولیدکننده منتظر تأیید دریافت بیام از بروکر نیست. (بدون اطمینان)
  - o تولیدکننده منتظر تأیید دریافت پیام از رهبر پارتیشن (Leader) است.
  - م acks=all :تولیدکننده منتظر تأیید دریافت پیام از همه رپلیکها (Replicas) است. (بیشترین اطمینان)

#### Commit

- Commit در Kafka فرایندی است که در آن مصرفکنندهها offset هایی را که پردازش کردهاند، به Kafka اعلام میکنند.
  - انواع:
- o خودکار (Kafka : (Auto Commit) به صورت دورهای و خودکار offset های پردازش شده را میکند.
- دستی(Manual Commit): مصرف کننده ها به صورت دستی و با استفاده از API های offset ، Kafka های offset ، Kafka های commit
   میکنند. این روش انعطاف پذیری بیشتری برای مدیریت پیامها و خطاها فراهم میکند.

#### Heartbeat

- Heartbeat :سیگنال هایی هستند که توسط مصرفکننده ها به گروه مصرفکننده (Consumer Group) ارسال می شوند تا وضعیت فعال بودن خود را اعلام کنند.
  - ، کاربرد:
  - اطمینان از اینکه مصرفکننده ها هنوز فعال و در حال کار هستند.
  - شناسایی مصرفکنندههای مرده یا غیر فعال و توزیع مجدد پارتیشنهای آنها بین مصرفکنندههای دیگر.

همچنین بهتر است بدانیم که کافکا باید برروی یک سیستمی که وظیفه ایجاد هماهنگی بین clusterهای آن را دارد، پیادهسازی شود در اینجاست که از Zookeeper استفاده میکنیم:

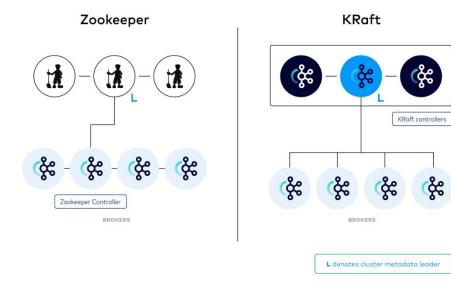
# Zookeeper:

- Zookeeper :یک سرویس هماهنگی توزیعشده است که Kafka از آن برای مدیریت اطلاعات متا، هماهنگی بین بروکرها و پیگیری وضعیت خوشه ها استفاده میکند.
  - وظایف:
  - o مدیریت ر هبران پارتیشنها(Leader election)
    - دخیره و مدیریت تنظیمات بروکرها
    - o پیگیری وضعیت مصرفکننده ها و offset ها

البته در سالهای اخیر و با پیشرفت دانش و تکنولوژی از ابزارهای دیگری هم به عنوان جایگزین برایZookeeper استفاده میشود که نمونه آن را در ذیل میتوانیم بررسی کنیم:

#### KRaft (Kafka Raft Metadata Mode):

- Kafka در حال انتقال به یک مدل جدید مدیریت متا به نام KRaft است که و ابستگی به Zookeeper را حذف میکند.
  - مزايا:
  - کاهش پیچیدگی معماری
  - o بهبود عملکرد و مقیاسیذیری
  - o افزایش یایداری و قابلیت اطمینان



Apache Kafka یک پلتفرم پیامرسانی توزیعشده است که بر ای دریافت، ذخیر هسازی و پر دازش داده های استریمینگ در زمان واقعي طراحي شده است. اين سيستم با استفاده از مفاهيمي چون Topics، پارتيشنها(Partitions) ، وoffset پیامها را به صورت مؤثر و قابل مقیاسپذیری مدیریت میکند . Kafka از ACK ها برای تأیید دریافت پیامها، و از commit ها برای مدیریت offsetهای پردازش شده توسط مصرفکننده ها استفاده میکند. این یلتفرم از Zookeeper یا Kraft برای هماهنگی و مدیریت متادیتاً بهره میبرد و با استفاده از سیگنالهای heartbeat وضعیت مصرفکنندهها را مانیتور میکند. Kafka با ویژگیهای مقیاسپذیری بالا، پایداری و قابلیت اطمینان، به یکی از ابزارهای محبوب در معماری های میکروسرویس و پردازش بلادرنگ تبدیل شده است.